AgentForge 多智能体编排与软件开发工作台

0 封面信息

- **赛题**：赛题一「Agent 编排创新应用」　**项目**：AgentForge 多智能体编排与软件开发工作台
- **队伍**：奶龙队　**学校**：湖北工业大学工程技术学院　**成员**：王拙诚、吴捍卫、黄浩　**指导教师**：刘浪
- **提交命名**：赛题一+奶龙队+AgentForge（官方队伍编号：2117173210695860225）
- **版本日期**：初赛提交版 v1.0，2026-11-12（初赛截止 2026-11-20）
- **运行形态**：本机 Web 工作台（React 19 + TypeScript 7 + Vite 8；FastAPI + SQLite；Python 3.13），候选代码只在 WSL2 内 Docker 执行；模型 deepseek-v4.1-flash（智云 API）

一句话：AgentForge 由模型动态拆任务、按依赖与写入范围并行派发，用独立 Docker 验收与语义审查做完成门控，并把调度依据、失败反馈、修正过程全部留成可回放事件——结论可追溯到原始回执，而不是模型自述。

1 选题背景与场景需求分析

单个 Agent 承担长任务会遇到上下文膨胀、角色混叠、失败不可归因三个问题；多 Agent 协作把任务交给上下文隔离的执行者，是自然解法，赛题也把 LobeHub、DeepSeek Harness 作为对标。真正的难点不是“多个 Agent 轮流说话”，而是：编排由任务本身决定而非提前写死；结果经过独立验证而非模型自称成功；失败形成结构化反馈并驱动有限、可控的迭代。不少同类作品停在“固定流水线 + 模型自述验收”，无法回答“凭什么相信这次通过”。

场景需求集中在三类用户：**高校课程与实训**需要可私有化、可解释、可复现的教学平台，学生能看到任务图、调度依据、Docker 回执与失败原因；**科研小工具**（数据脚本、CLI、小型 Web 页）边界清晰、验收可自动化，适合 Agent 快速实现并留证据链；**企业研发提效**要求模型可替换、源码不出内网、执行受控、失败不静默降级。共同需求六点：本地化与密钥不外泄、多 Agent 动态协作、结果可信、失败可解释可迭代、运行可回放可复现、模型与工具可替换。

选择软件开发作为首个场景，是因为验收可机器判定（独立单测、HTTP 测试、容器退出码），能把“编排是否有效”与“模型口才”分开评估；平台主体是通用编排器，替换 Agent、工具与工作流即可迁移。初赛取舍：把一条真实闭环做深，不宣称通用软件工程能力，也不宣称普遍效率提升。**核心优势**可概括为三点：模型驱动的动态编排而非硬编码流水线；独立验收与哈希绑定使结果可验证；事件、快照与复现包使运行可审计、可复现。

典型使用流程（以课程实训为例）：教师导入示例项目与需求，学生在界面输入任务；平台冻结验收并动态派发，学生查看协作图与失败反馈；教师用导出的事件与哈希作为评分依据。这条流程已在 Flask 看板和记账 CLI 两个案例上真实走通。需求边界：平台当前只接受有界标准库 Python 多文件项目、JSON 可传递的函数接口，以及固定 wheel 依赖的 Python Web 项目；任意大型仓库、自动安装任意依赖、常驻生产服务不在初赛范围。

2 平台总体架构设计与技术选型

2.1 分层架构

平台分六层，自下而上所有执行事实由宿主记录，模型只能提出动作。

```
[交互层] React 19 / TypeScript 7 / Vite 8（对话、项目、协作图、交付页）
    | HTTP /api（40 条路由）
    v
[API 层] FastAPI + SQLite（5 库、16 种表结构）
    | 运行、事件、步骤、快照、版本、验收回执
    v
[编排内核] 主 Agent 决策 → 动态任务图 → 调度 → 门控 → 预算收尾
    | 派发任务 / 调用工具
    v
[执行与工具层] 模型适配、知识检索、文件编辑、项目/Web 工具
    | 候选源码
    v
[隔离验收层] WSL2 内 Docker Engine（禁网、只读、非 root、限额）
    | 验收回执、候选哈希
    v
[证据层] 事件、快照、候选哈希、验收回执、独立审查、ZIP 复现包
```

一次自主运行：提交需求 → 主 Agent 拟定并冻结验收 → 模型 `dispatch` 建任务（名称、指令、依赖、写入范围）→ 宿主校验依赖、环、写入冲突与预算后并行执行 → 每批结束交还控制权 → 候选哈希绑定 Docker 验收 → 语义审查 → `finish` 门控。

证据优先：每次工具调用、候选写入、容器执行与审查结论都先写事件再更新状态；成功节点与恢复上下文在同一事务提交，避免“节点成功但输出丢失”。

2.2 技术选型

层	选型	理由	边界
前端	React 19 + TS 7 + Vite 8，19 文件 3,268 行	事件驱动详情、协作图、时间轴回放需强类型状态	无路由框架
后端	FastAPI + Python 3.13，21 模块 6,958 行、40 API	异步接口、校验、OpenAPI	单机单进程，无多用户认证
存储	SQLite 5 库、16 种表结构	事务、不可变版本、零运维、整库快照取证	无分布式
隔离	WSL2 内 Docker Engine + Python 3.13 镜像	候选不在宿主机执行，可限网络、权限、资源	WSL 单点；父子同 UID
模型	deepseek-v4.1-flash（智云 API）	支持工具调用与 JSON 输出，成本适合多轮实验	429、格式错误、未知用量均有记录
知识	`knowledge/*.md` 关键词检索	轻量可解释，无需向量设施	非向量库，最多 3 条片段

2.3 开源使用与自定义改进

使用 React、Vite、TypeScript、FastAPI、Uvicorn、SQLite 等开源组件（许可证见 `docs/third-party.md`）。编排层**未套用 LangChain、AutoGen 等框架**：本平台要把每次调度、每个工具结果、每份候选哈希写成可验证事件，要在同一内核实现模型驱动与模板两条路径，且完成门控要求“模型提议、宿主裁决”。相对通用框架的自定义改进：能力与工具权限双重筛选、低负载优先与专用 Agent 排序、失败重派、验证子工作流并行、候选哈希失效、SQLite 原子节点检查点、配置版本快照、收尾预算预留。

2.4 赛题要求覆盖

要求	对应实现	章节
① 五核心模块	Agent 定义配置、工作流编排、调度执行、验证监控、反馈优化	2–6
② 可运行原型	工作台 + 40 API + 真实模型 + 真实 Docker + 复现包	6、7、附录 A
③ 多 Agent 协作	主 Agent 动态派发，子 Agent 上下文隔离、并行、可回放	3、4
④ 自我循环	执行→验收→反馈→修正→复验；依据真实失败补派任务	4.4
⑤ LLM 推理核心	拆分、指令、编码、验收生成、语义审查均由模型完成	3、8
⑥ 智能调度	任务图由模型决定，宿主只强制依赖、权限、写入互斥、并发、预算	4.1–4.3
⑦ 工具/RAG/记忆	Function Calling 工具、本地 RAG、任务级记忆；MCP/A2A 未接入	3.4、8
⑧ 开源自定义改进	见 2.3，依赖与原创边界见 `docs/third-party.md`	2.3

这张表同时是自查清单：①–⑥ 均有可运行实现与真实运行证据；⑦ 只实现了 Function Calling 与本地 RAG，MCP/A2A 与向量库如实标为未完成；⑧ 的第三方依赖与原创边界逐项记录，不把开源组件包装成原创工作。

3 Agent 角色定义、工作流设计与编排逻辑

3.1 Agent 定义与团队

每个 Agent 由名称、角色、能力标签、允许工具、提示词、模型和启用状态定义；能力标签限定 `plan/develop/test/review/fix`，工具名由后端白名单校验。每次保存产生新版本，历史运行固定使用当时版本；运行开始时把 Agent 配置、工作流定义、知识版本冻结进快照。Agent 团队即一次运行中启用的 Agent 集合：模板路径按节点能力从团队中选择执行者，自主路径由主 Agent 按需创建子任务，不强制五个角色全部出场。

角色	能力	允许工具	职责
主 Agent	自由描述	派发/取消/验证/结束控制动作	读需求与反馈，决定下一步并生成子任务
规划	plan	read_project、knowledge_search	分析需求与结构，拆分任务
开发	develop	read_project、candidate_diff	生成候选源码与差异
测试	test	run_acceptance、read_project	读取容器验收结果并解释
审查	review	read_project、knowledge_search	对照需求检查覆盖与风险，给出 `passed`
修正	fix	read_project、candidate_diff	依据真实失败反馈修正候选

3.2 三条执行路径

路径	任务图来源	执行方式	验证
legacy 模板 DAG	代码定义的开发/审查模板	顺序、并行、条件、循环、子工作流，最多 2 轮修正	验收子工作流 + 汇总审查 + 门控
autonomous（主入口）	模型运行中动态生成	任意任务、依赖、写入范围，就绪任务并行	冻结 Docker 验收 + 语义审查 + `finish` 门控
项目 / Web 项目模式	主 Agent 直接编辑或派发	不可变版本、回归验收继承；Web 锁 wheel、离线镜像、iframe 预览	全量回归 + 审查 + 用户确认应用

真实例子：Web 看板需求在运行中被拆成 `impl-backend-api` 与 `impl-frontend` 两个无依赖任务，写入范围分别为 `app.py` 与 `static/`，因此同批并行；记账项目则由主 Agent 直接编辑 `ledger.py` 与 `main.py`，说明团队规模由任务决定，而不是按角色硬凑。

3.3 自主编排逻辑

1. **需求与冻结**：主 Agent 阅读需求、源码与已有验收，拟定并冻结本轮验收；子 Agent 无权修改验收。
2. **动态拆任务**：模型 `dispatch` 任意命名任务并给出指令、依赖、写入范围；宿主校验 ID 唯一、依赖存在且无环、写入范围合法。
3. **并行执行**：依赖已成功且写入路径不重叠的任务同批并发（上限 3），每个任务有独立子 Agent 上下文。
4. **交还控制权**：每批结束主 Agent 读取真实结果，选择 `continue`、`dispatch`（补派/替换）、`cancel`、`verify` 或 `finish`。

5. **验证与审查**：验收在禁网、只读、非 root、capabilities 丢弃、限额容器中运行，通过后由审查 Agent 做语义审查。
6. **完成门控**：`finish` 只是提议，宿主检查候选哈希已通过隔离验收、无待执行任务、审查通过才结束。

规则上，所有子任务共享同一份冻结验收；子 Agent 不能修改验收、不能扩大自己的工具权限，也不能读取其他任务的完整上下文。

3.4 知识库定义与集成、协作图与记忆

平台不展示“思维链”，而把事件投影成协作图：节点代表任务、工具调用、Docker 回执或审查结论，连线代表派发、依赖与反馈；点击节点可看分工、指令、涉及文件与真实回执，时间轴支持逐步、播放、暂停和回到实时，回放只读事件、不调用模型。知识库由 `knowledge/` 下 UTF-8 Markdown 定义（当前含开发规范、需求说明、测试说明），按英文词与中文字符匹配计分，返回最多 3 条片段及文件路径进入 Agent 上下文，模型也可经授权的 `knowledge_search` 再检索；项目模式把资料冻结为版本后再检索。须如实说明：这是本地关键词检索，**不是向量数据库或 embedding RAG**；记忆是任务级记忆（冻结上下文、事件、快照），不是跨任务长期自主学习。项目模式中，“记账项目约定”资料 v1 的版本 hash 与检索节选真实进入模型请求，事件记录 `knowledge_retrieved`；修改配置或资料后需新建运行才会生效。

4 调度算法与自我循环机制

4.1 模板工作流调度

```
ready = 依赖均已成功持久化的节点；未知依赖或成环 → 明确失败
按（优先级降序，节点 ID 升序）取就绪节点
候选 = enabled 且具备所需能力与全部必需工具权限的 Agent
排序 =（当前负载升序，能力标签数升序，Agent ID 升序）
分配给首个候选，负载 +1；结束/失败/取消时释放
失败 → 排除该 Agent，最多再尝试 1 个其他匹配 Agent
无候选/超时/结构化输出无效 → 明确错误；全部依据写入事件
```

能力标签数平局依据只表示“职责更专用”，不代表已验证的模型质量；当前负载是单进程计数，没有抢占、成本最优化或训练得到的策略。失败重派只允许换一个匹配 Agent，避免同一错误在多个 Agent 上无限重试；排除原因与候选列表全部落事件，便于复盘。

4.2 自主编排的动态调度

```
主 Agent 输出 dispatch/continue/verify/finish/stop
宿主校验：ID 唯一、依赖存在且无环、写入范围合法、预算足够
batch = 依赖全部成功 且 写入路径两两互斥 的就绪任务（≤3）
并行执行 batch，逐任务记录起止、工具回执与候选哈希
batch 结束 → 真实结果交还主 Agent 决定下一步
候选一经修改 → 旧验收立即失效，必须重新 verify
```

与模板路径的关键差别：节点由模型根据需求、上一批结果和真实验收反馈生成；宿主只强制不能交给模型的约束（权限、依赖、写入互斥、并发、预算、完成判据）。这就是“智能化而非硬编码”的落点。真实决策链中，报表任务遇到 HTTP 429 后，主 Agent 创建了新 ID 的替代任务而不是静默重跑旧任务，最终整体通过；失败与替代关系都保留在事件里。

4.3 模型决定与宿主强制的边界

模型决定	宿主强制
任务拆分、名称、指令、依赖建议、写入范围	ID 唯一、依赖存在且无环、路径白名单
是否补派/替换/取消、何时验证、是否结束	写入互斥、并发上限、步数/时间/调用/token 预算、验收冻结、哈希绑定与完成门控

4.4 自我循环

自我循环分两层。**模板路径**：执行→验收→反馈→修正→复验，最多 2 轮；测试与初审真实并发，再汇总审查，门控选择结束、修正或转人工。**自主编排**：主 Agent 读取真实 Docker 失败与审查意见，自行创建修复任务、替换失败任务或收尾；失败任务不静默重跑，但可创建新 ID 的替代任务。

阶段	输入	动作	终止
执行	任务图与候选	子 Agent 生成候选或工具执行	全部结束/失败/预算耗尽
验收	冻结验收 + 候选哈希	容器内独立测试	完整通过/失败回执
反馈	stdout/stderr、失败项	分类为代码/协议/环境	写入事件并进入上下文
修正	真实失败反馈	修正 Agent 或新任务生成新候选	候选哈希变化
复验	新候选	重跑冻结验收	通过、轮次用尽或转人工

收尾预算（finishing-budget-v1）：新运行在原有总预算内为最终验收与审查预留最多 2 次调用、总 token 的 20%（≤65,536）、1 次验收、1 个决策步骤、总时间的 20%（≤60 秒），调用预留不超过总数 1/4；接近阈值时记录事件并进入收尾，停止委派、改文件与调用应用工具，但不扩大预算或跳过检查。旧运行沿用原路径，历史结果不回填。运行同时受 24 个决策步、32 项任务、8 次验收、900 秒等上限约束，任一触顶即进入收尾或待处理，不会无限循环。

4.5 失败分类与保留

失败拆成可区分类别分别留证：自然代码失败、JSON 协议/格式失败与格式重试、HTTP 429 等服务错误、预算拒绝、容器阻塞、导入基线未实现。格式重试不计为代码修正，429 不计为代码失败，导入基线失败不归因于模型。须如实说明：**现有自然代码失败后自动修正的样本仍然缺失**，已验证的修正闭环来自明确标注的预设缺陷实验，不等于自然开发中的自修复成功率。

5 结果验证策略与反馈优化逻辑

5.1 验证原则

只有与模型无关的外部证据才算通过。模型写 `test: passed`、伪造 `tool_calls` 或自称完成都不改变宿主记录；成功同时要求运行器报告测试通过、隔离成立、退出码为零、审查 `passed` 为真，且候选哈希与验收时一致。

5.2 隔离验收链

候选只在容器执行：关闭网络、只读根文件系统与代码/验收挂载、非 root、丢弃 capabilities、限制内存/CPU/进程，外层超时后清理。可信测试驱动在父进程，候选由独立 worker 子进程经受限 JSON 协议提供行为，候选标准输出不会直接转发为验收结果；返回引用变更经代理回传，避免序列化掩盖“应返回副本”的验收条件。回执含候选摘要、冻结验收摘要、实际测试数、失败/错误数、退出码与隔离标识；候选哈希↔回执 nonce↔独立审查三者绑定，任一不一致都不能宣告成功。例如一次 CSV 报表任务的首轮容器验收出现 12 项错误（初始脚手架尚未实现），宿主把真实 stdout/stderr 交回主 Agent；主 Agent 据此判断不是最终候选缺陷，继续开发后第二次验收通过。首轮失败被单独标注，不混入自然代码失败统计。

5.3 应用门控与项目模式

候选与目标分离，平台不自动应用或推送。用户确认后，应用接口重新比较已验证摘要并检查目标基线冲突，才写入受控目标；应用串行化防并发覆盖。项目模式每个版本不可变，新一轮继承选定版本的源码与全部回归验收（记账项目从 6 项既有验收扩展到 13 项、20 项），候选变化使旧验证立即失效。

5.4 证据分级

等级	证据	能证明	不能证明
L0	模型自述	模型表达了什么	任何执行结果
L1	工具回执/退出码	调用确实发生并返回	验收标准是否正确
L2	独立 Docker 验收 + 哈希绑定	候选通过冻结测试	业务语义完全正确
L3	用户确认 + 基线冲突检查	结果被人工接受并落地	长期生产可用性

界面按这四级展示证据来源：测试通过但审查未过、审查通过但未应用、候选变化导致验证失效，都会显示为不同状态，而不是统一显示“成功”。

5.5 反馈优化与局限

指标包括 `model_calls`（已尝试请求数）、`model_tokens`（服务端 usage）、`agent_invocations`；用量缺失保留 `model_metrics_complete=false`，只当已知下界，绝不把未知用量写成 0。反馈优化体现在：失败分类决定修复对象（代码/协议/环境分别处置）；预算预留避免“开发花光预算、最后无法验收”；候选变化使旧验证失效、强制重验，防止旧回执为新代码背书。局限：AI 验收可能与生成代码的模型同源，存在共同盲区；同容器同 UID 非强对抗沙箱；Web 预览成功不替代 Docker 验收；测试通过不等于业务完全正确，以上均在界面与文档中标注。

6 核心代码模块说明与系统截图

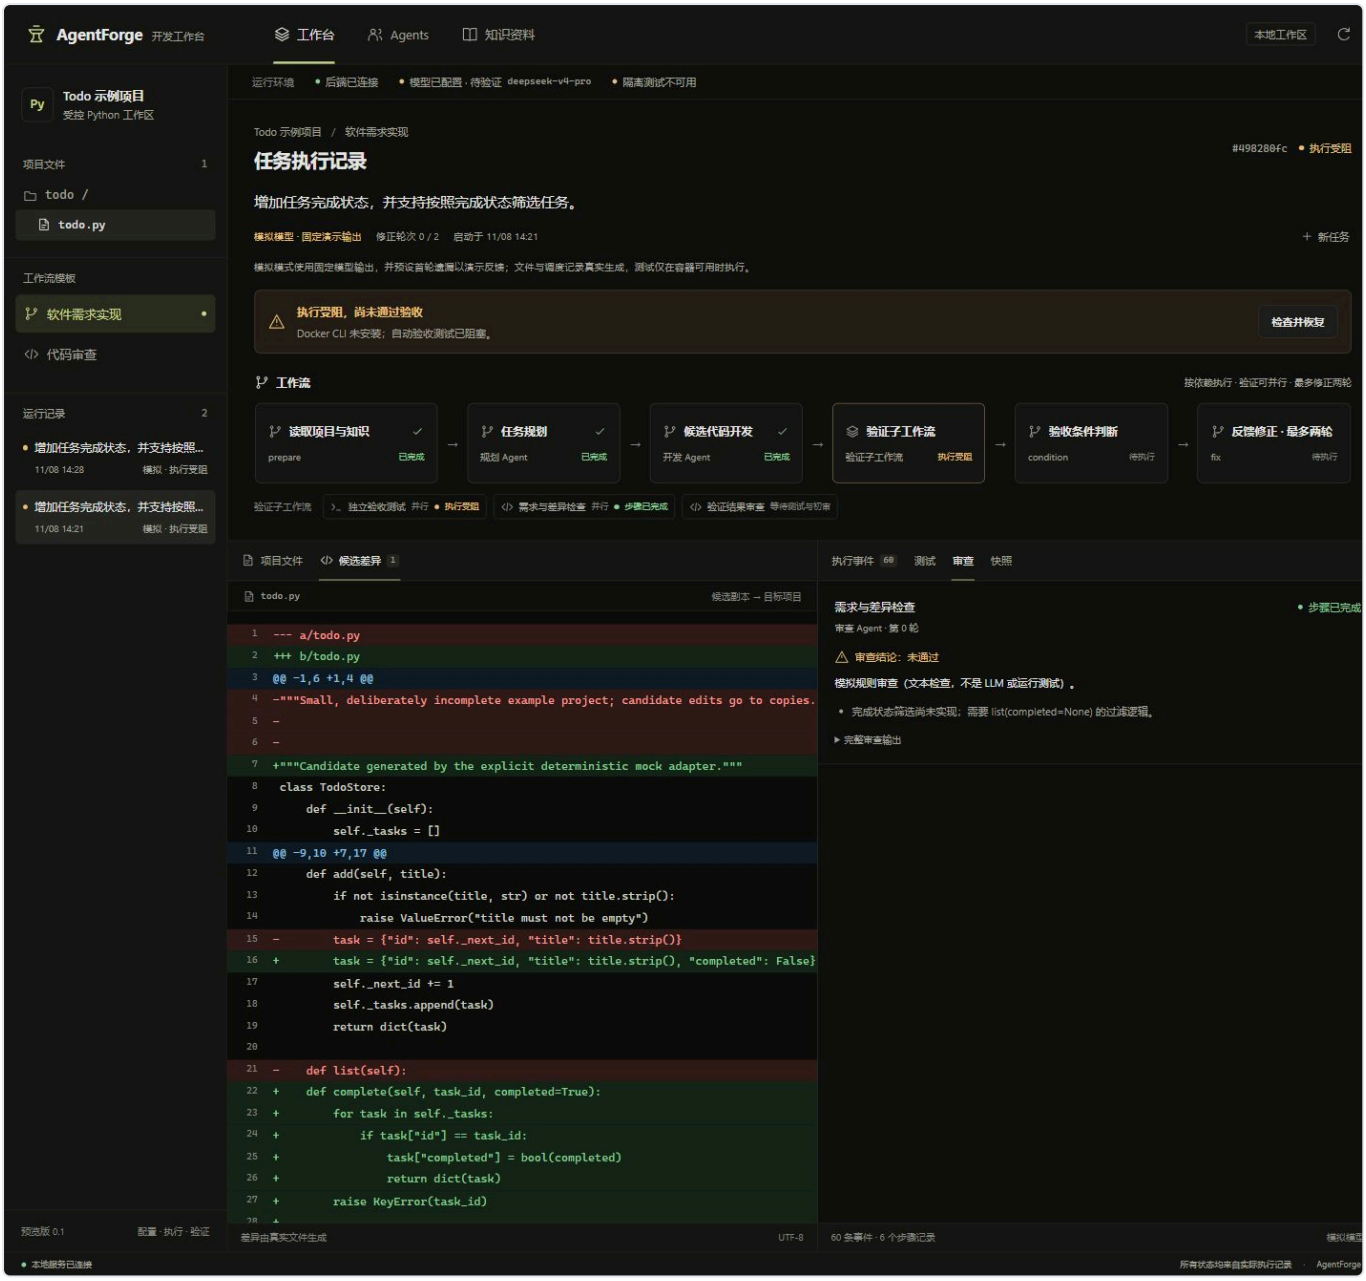
6.1 后端模块

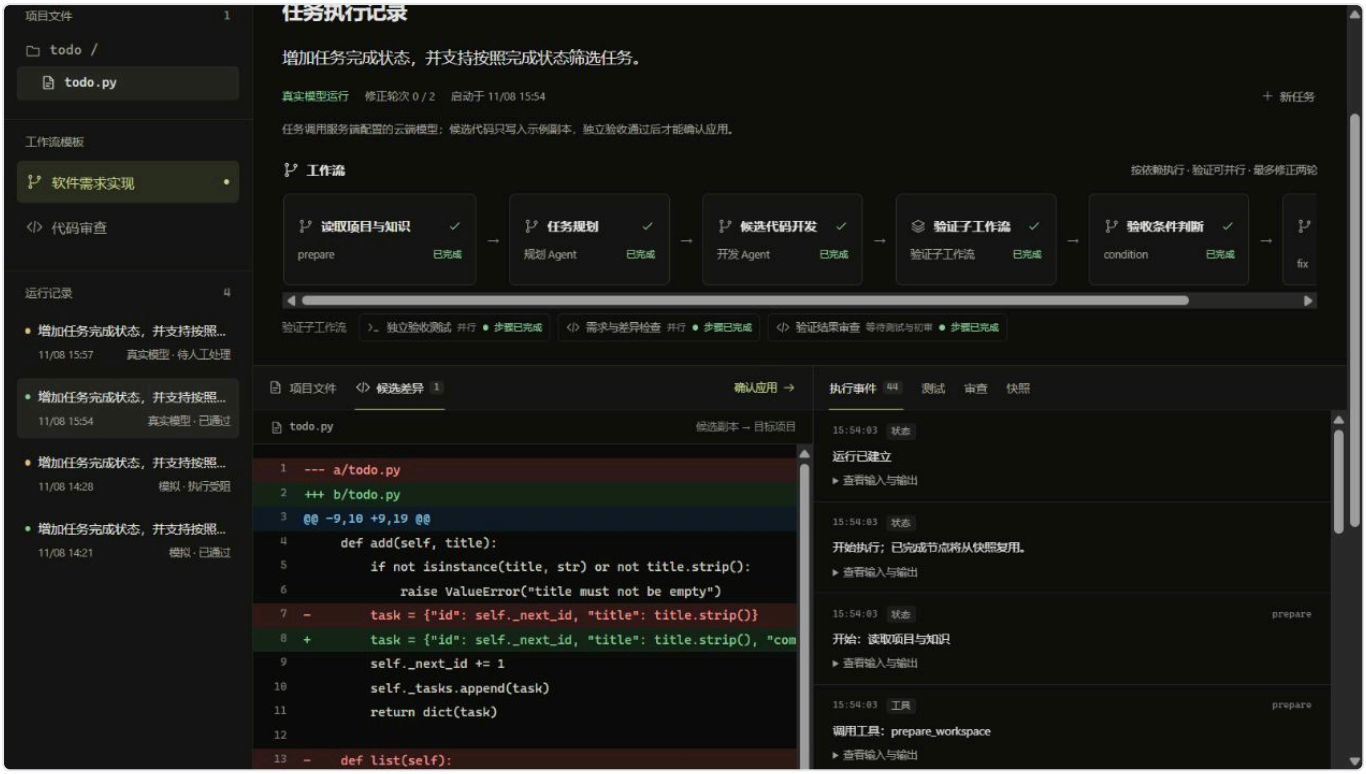
模块（文件）	行数	职责
`autonomous_model.py`、`autonomous.py`、`finishing_budget.py`	2,026	主 Agent 决策循环、任务图校验、预算与收尾
`engine.py`、`definitions.py`	458	模板 DAG 执行、调度、验证门与有限修正
`runtime.py`	569	模型适配、工具白名单、知识检索、差异与容器测试
`autonomous_sandbox.py`	359	容器内可信验收驱动与候选 worker 协议
`projects.py`、`projects_api.py`、`project_runner.py`、`project_tools.py`	1,086	项目、不可变版本、运行、应用工具
`web_preview.py`、`web_dependencies.py`、`web_api.py`、`web_tools.py`、`web_config.py`	1,368	Web 依赖冻结、离线镜像、预览生命周期
`comparison.py`	506	三组对照实验运行器与证据归档
`app.py`、`storage.py`、`autonomous_api.py`、`task_catalog.py`	585	API 装配、SQLite 持久化、任务目录
合计（21 模块 + 1 行包声明）	6,958	后端总规模

前端 19 文件 3,268 行：`App.tsx` 424 行负责视图与详情装配，项目工作区 305、协作图投影 355、协作图视图 257，数据访问层约 623，样式约 725。后端 40 条 API 覆盖运行、事件、候选、项目版本、Web 依赖与预览；SQLite 5 库、16 种表结构（主库与自主库共享 5 表，项目库 6 表，请求库 2 表，Web 请求库 3 表）。关键实现点：候选写入前做路径白名单与大小校验并生成 unified diff；验收上下文按轮次与候选哈希隔离；模型请求与工具调用记录调用者、参数摘要与结果状态；失败恢复只重跑未成功节点。

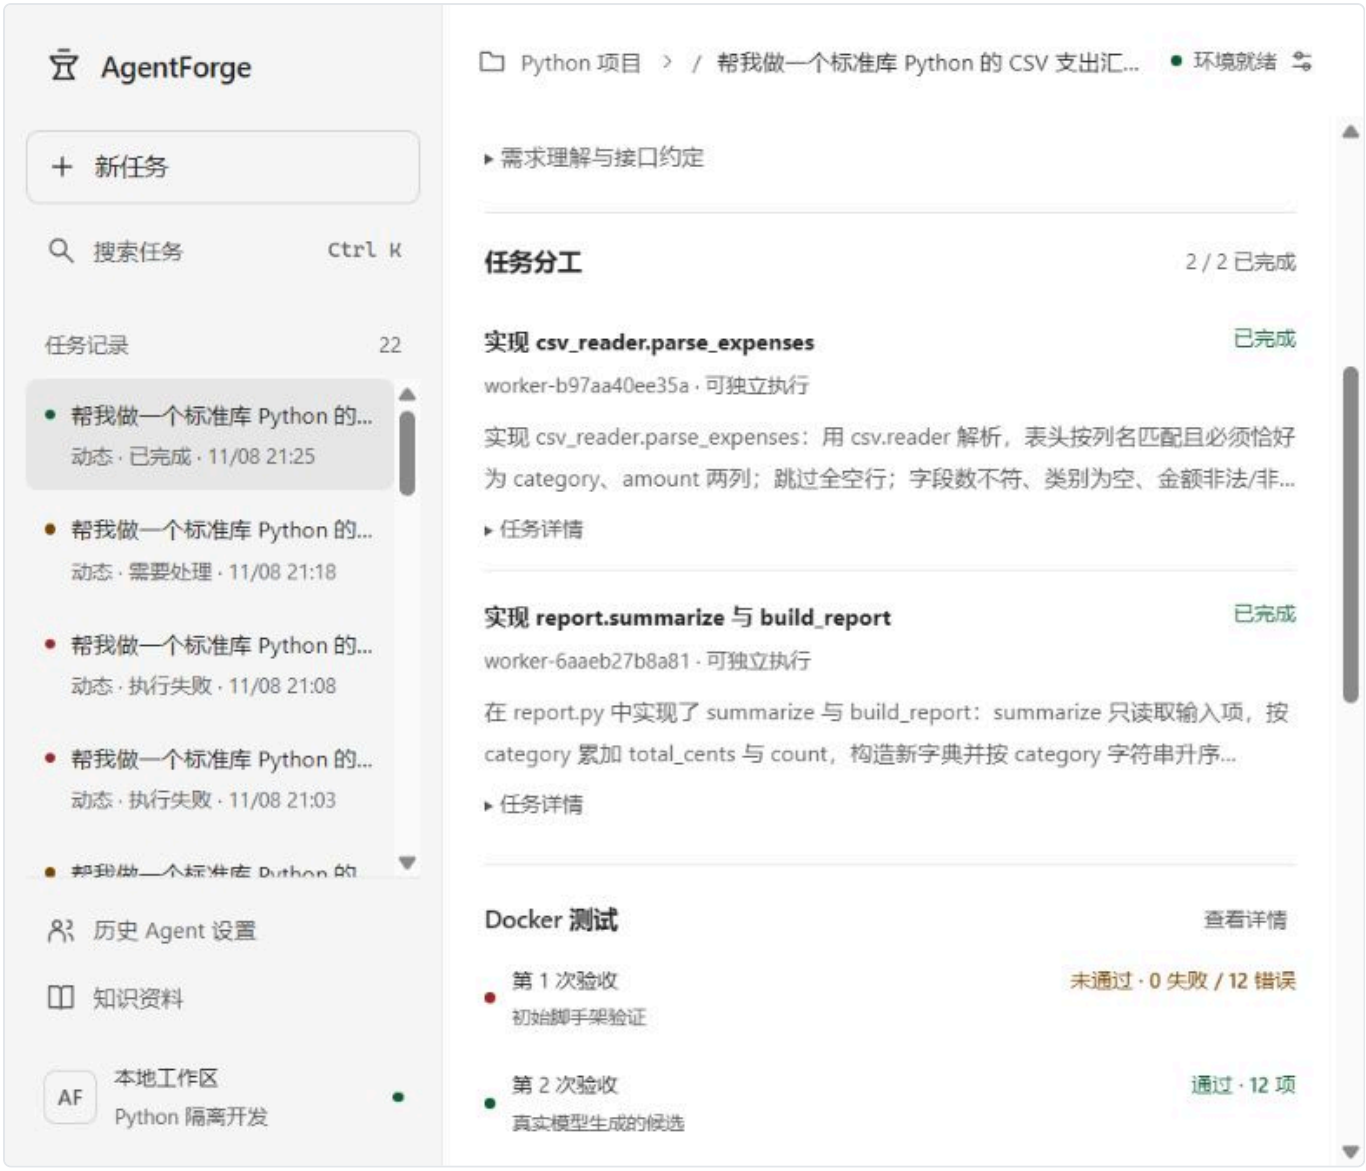
6.2 系统截图

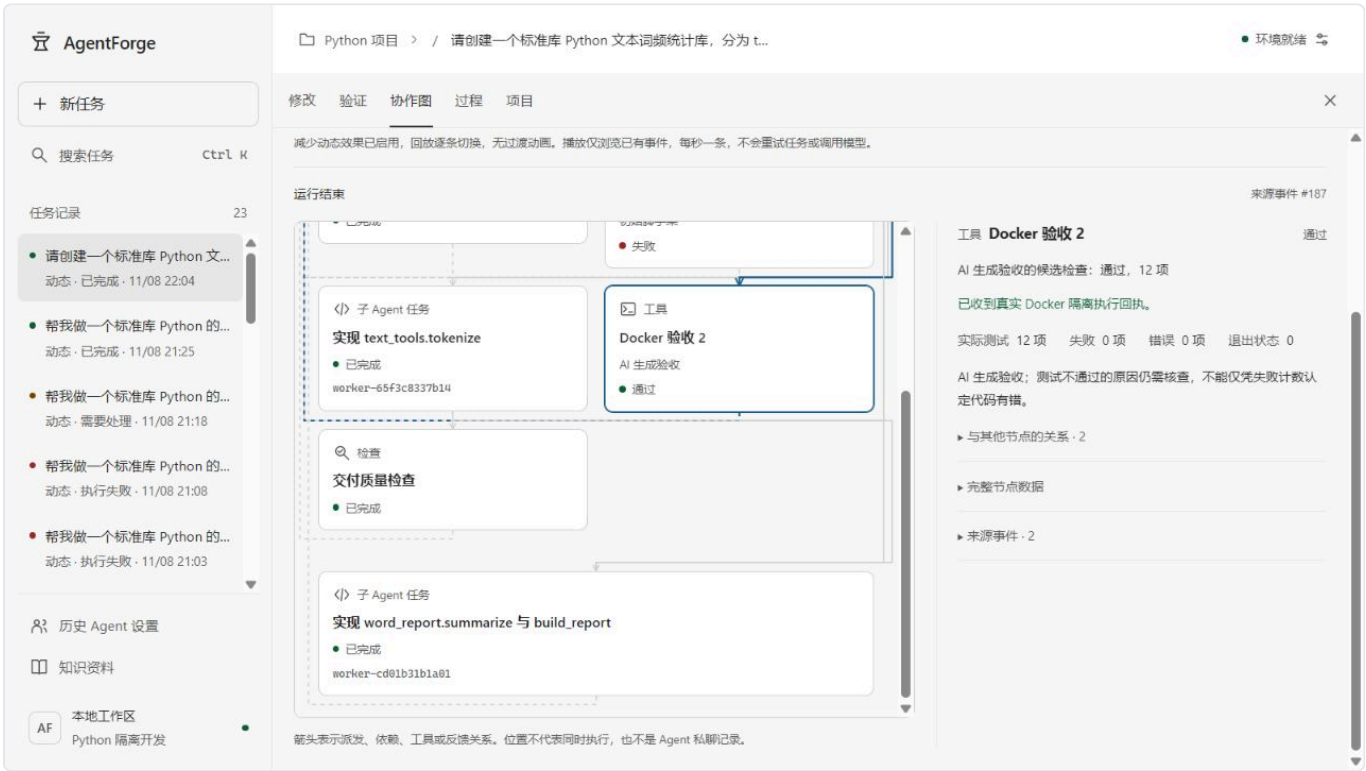
以下为真实界面截图，路径相对 `submission/`；早期深色界面或模拟演示截图已在图注标注，真实证据以第 7 章与附录 B 为准。注：部分历史截图扩展名为 `.png`，实际编码为 JPEG，PDF 导出时按实际格式处理。截图只用于展示界面与交互，不替代原始 JSON 回执；每张图对应的运行与证据文件可在第 7 章与附录 B 定位。


AgentForge 开发工作台
工作台
Agents
知识资料
本地工作区
Py
Todo 示例项目
受控 Python 工作区
项目文件 1
todo /
todo.py
工作流模板
软件需求实现
代码审查
运行记录 2
增加任务完成状态，并支持按照...
11/08 14:28 模拟 · 执行受阻
增加任务完成状态，并支持按照...
11/08 14:21 模拟 · 执行受阻
预览版 0.1
配置 · 执行 · 验证
本地服务已连接
运行环境 后端已连接 模型已配置 · 待验证 deepseek-v4-pro 隔离测试不可用
Todo 示例项目 / 软件需求实现
任务执行记录
#498288fc 执行受阻
增加任务完成状态，并支持按照完成状态筛选任务。
模拟模型 · 固定演示输出 修正轮次 0 / 2 启动于 11/08 14:21
+ 新任务
模拟模式使用固定模型输出，并预设首轮遗漏以演示反馈；文件与调度记录真实生成，测试仅在容器可用时执行。
执行受阻，尚未通过验收
Docker CLI 未安装；自动验收测试已阻塞。
检查并恢复
工作流
按依赖执行 · 验证可并行 · 最多修正两轮
读取项目与知识
prepare
已完成
任务规划
规划 Agent
已完成
候选代码开发
开发 Agent
已完成
验证子工作流
验证子工作流
执行受阻
验收条件判断
condition
待执行
反馈修正 · 最多两轮
fix
待执行
验证子工作流
独立验收测试 并行 执行受阻
需求与差异检查 并行 步骤已完成
验证结果审查 等待测试与初审
项目文件
候选差异 1
todo.py
候选副本 → 目标项目
--- a/todo.py
+++ b/todo.py
@@ -1,6 +1,4 @@
-"""Small, deliberately incomplete example project; candidate edits go to copies.
-
-
+"""Candidate generated by the explicit deterministic mock adapter."""
class TodoStore:
def __init__(self):
self._tasks = []
@@ -9,10 +7,17 @@
def add(self, title):
if not isinstance(title, str) or not title.strip():
raise ValueError("title must not be empty")
- task = {"id": self._next_id, "title": title.strip()}
+ task = {"id": self._next_id, "title": title.strip(), "completed": False}
self._next_id += 1
self._tasks.append(task)
return dict(task)
- def list(self):
+ def complete(self, task_id, completed=True):
+ for task in self._tasks:
+ if task["id"] == task_id:
+ task["completed"] = bool(completed)
+ return dict(task)
+ raise KeyError(task_id)
差异由真实文件生成
UTF-8
执行事件 60
测试
审查
快照
需求与差异检查
步骤已完成
审查 Agent · 第 0 轮
审查结论：未通过
模拟规则审查（文本检查，不是 LLM 或运行测试）。
完成状态筛选尚未实现：需要 list(completed=None) 的过滤逻辑。
完整审查输出
60 条事件 · 6 个步骤记录
所有状态均来自实际执行记录 · AgentForge


项目文件 1
todo /
todo.py
工作流模板
软件需求实现
代码审查
运行记录 4
增加任务完成状态，并支持按照...
11/08 15:57 真实模型 · 待人工处理
增加任务完成状态，并支持按照...
11/08 15:54 真实模型 · 已通过
增加任务完成状态，并支持按照...
11/08 14:28 模拟 · 执行受阻
增加任务完成状态，并支持按照...
11/08 14:21 模拟 · 已通过
任务执行记录
增加任务完成状态，并支持按照完成状态筛选任务。
真实模型运行 修正轮次 0 / 2 启动于 11/08 15:54
+ 新任务
任务调用服务端配置的云端模型；候选代码只写入示例副本，独立验收通过后才能确认应用。
工作流
按依赖执行 · 验证可并行 · 最多修正两轮
读取项目与知识 prepare 已完成
任务规划 规划 Agent 已完成
候选代码开发 开发 Agent 已完成
验证子工作流 验证子工作流 已完成
验收条件判断 condition 已完成
fix
验证子工作流 独立验收测试 并行 步骤已完成
需求与差异检查 并行 步骤已完成
验证结果审查 等待测试与初审 步骤已完成
项目文件
候选差异 1
确认应用 →
todo.py
候选副本 → 目标项目
--- a/todo.py
+++ b/todo.py
@@ -9,10 +9,19 @@
def add(self, title):
if not isinstance(title, str) or not title.strip():
raise ValueError("title must not be empty")
- task = {"id": self._next_id, "title": title.strip()}
+ task = {"id": self._next_id, "title": title.strip(), "com
self._next_id += 1
self._tasks.append(task)
return dict(task)
- def list(self):
执行事件 4
测试
审查
快照
15:54:03 状态
运行已建立
查看输入与输出
15:54:03 状态
开始执行；已完成节点将从快照复用。
查看输入与输出
15:54:03 状态 prepare
开始：读取项目与知识
查看输入与输出
15:54:03 工具 prepare
调用工具：prepare_workspace
查看输入与输出


AgentForge
工作台
Agents
知识资料
后端已连接
模型调用已验证 deepseek-v4.1-flash
隔离测试可用
Py
Todo 示例项目
JSON 导入、导出与原子合并
运行基线 1
todo /
todo.py
工作流模板
软件需求实现
代码审查
运行记录 16
JSON 导入、导出与...
11/08 17:09 真实模型 · 已通过
优先级与稳定分页查询
11/08 17:08 真实模型 · 已通过
批量编辑与原子更新
11/08 真实模型 · 已通
JSON 导入、导出与原子合并 / 软件需求实现
#c1777cf1 已通过
任务执行记录
JSON 导入、导出与原子合并
完整运行需求
真实模型运行 默认模型：deepseek-v4.1-flash 修正轮次 0 / 2 启动于 11/08 17:09
+ 新任务
候选来源：真实模型开发 · 未注入缺陷
此评测任务仅使用真实模型与独立容器验收。基线保持冻结，候选保留并可导出。
工作流
按依赖执行 · 验证可并行 · 最多修正两轮
读取项目与知识 prepare 已完成
任务规划 规划 Agent 已完成
候选代码开发 开发 Agent
验证子工作流
独立验收测试 并行 步骤已完成
需求与差异检查 并行 步骤已完成
验证结果审查 等待测试与初审 步骤已完成
运行基线
候选差异 1
导出候选
todo.py
本次运行冻结基线


AgentForge
新任务
搜索任务 Ctrl K
任务记录 22
帮我做一个标准库 Python 的...
动态 · 已完成 · 11/08 21:25
帮我做一个标准库 Python 的...
动态 · 需要处理 · 11/08 21:18
帮我做一个标准库 Python 的...
动态 · 执行失败 · 11/08 21:08
帮我做一个标准库 Python 的...
动态 · 执行失败 · 11/08 21:03
历史 Agent 设置
知识资料
AF
本地工作区
Python 隔离开发
Python 项目 / 帮我做一个标准库 Python 的 CSV 支出汇...
环境就绪
需求理解与接口约定
任务分工
2 / 2 已完成
实现 csv_reader.parse_expenses
已完成
worker-b97aa40ee35a · 可独立执行
实现 csv_reader.parse_expenses：用 csv.reader 解析，表头按列名匹配且必须恰好为 category、amount 两列；跳过全空行；字段数不符、类别为空、金额非法/非...
任务详情
实现 report.summarize 与 build_report
已完成
worker-6aaeb27b8a81 · 可独立执行
在 report.py 中实现了 summarize 与 build_report：summarize 只读取输入项，按 category 累加 total_cents 与 count，构造新字典并按 category 字符串升序...
任务详情
Docker 测试
查看详情
第 1 次验收
初始脚手架验证
未通过 · 0 失败 / 12 错误
第 2 次验收
真实模型生成的候选
通过 · 12 项


AgentForge
新任务
搜索任务 Ctrl K
任务记录 23
请创建一个标准库 Python 文...
动态 · 已完成 · 11/08 22:04
帮我做一个标准库 Python 的...
动态 · 已完成 · 11/08 21:25
帮我做一个标准库 Python 的...
动态 · 需要处理 · 11/08 21:18
帮我做一个标准库 Python 的...
动态 · 执行失败 · 11/08 21:08
帮我做一个标准库 Python 的...
动态 · 执行失败 · 11/08 21:03
历史 Agent 设置
知识资料
AF
本地工作区
Python 隔离开发
Python 项目 / 请创建一个标准库 Python 文本词频统计库，分为 t...
环境就绪
修改 验证 协作图 过程 项目
减少动态效果已启用，回放逐条切换，无过渡动画。播放仅浏览已有事件，每秒一条，不会重试任务或调用模型。
运行结束
来源事件 #187
失败
子 Agent 任务
实现 text_tools.tokenize
已完成
worker-65f3c8337b14
工具
Docker 验收 2
AI 生成验收
通过
检查
交付质量检查
已完成
子 Agent 任务
实现 word_report.summarize 与 build_report
已完成
worker-cd01b31b1a01
工具 Docker 验收 2
通过
AI 生成验收的候选检查：通过，12 项
已收到真实 Docker 隔离执行回执。
实际测试 12 项 失败 0 项 错误 0 项 退出状态 0
AI 生成验收：测试不通过的原因仍需核查，不能仅凭失败计数认定代码有错。
与其他节点的关系 · 2
完整节点数据
来源事件 · 2
箭头表示派发、依赖、工具或反馈关系。位置不代表同时执行，也不是 Agent 私聊记录。





7 测试用例、运行效果与性能评估

7.1 测试设计

四层证据分开统计：平台单元/集成测试（编排、调度、权限、失败、循环、恢复，明确 StubRuntime 与模拟网络）；独立验收（`acceptance/` 与 `benchmarks/` 中维护者冻结、只在 Docker 运行）；前端组件测试与构建；真实运行证据（真实模型 + 真实容器）。平台测试通过不作为模型效果证据。具体用例包括成对正向/负向探针：正确参考实现须通过 10 项验收，缺筛选、跨实例共享状态、返回可变引用、伪造成功输

出、忙循环五类负例须分别被拒绝；前端测试覆盖任务状态、错误分类、项目版本与预览生命周期，其中新增 11 项交付证据测试与 2 项收尾状态展示测试。

7.2 平台回归与构建

项目	结果	证据
后端完整回归	872 passed，278 subtests passed，121.04 秒	`../output/delivery-readiness-20261110/pytest-final.txt`
前端测试	110 项通过、0 失败，369.3 毫秒（11-10 原始记录；11-12 复跑结果见下）	`../output/delivery-readiness-20261110/frontend-final.txt`
前端构建	tsc + Vite 通过，156 毫秒（11-10 原始记录；11-12 复跑结果见下）	`../output/delivery-readiness-20261110/frontend-final-build.txt`

构建产物 JS 386.17 kB（gzip 118.37 kB）、CSS 52.85 kB（gzip 10.27 kB）。六项合成容器探针验证：正确参考实现通过，缺筛选、跨实例共享状态、返回可变引用、伪造成功输出、忙循环超时分别被拒绝，探针后残留容器 0、模型调用 0。2026-11-12 本机独立复跑：后端 872 passed + 278 subtests（240.78 秒，加载压力下耗时约为记录值 2 倍）、前端 110 项通过（0.57 秒）、前端构建通过；同时 preflight 退出码 0，Docker 沙箱探针 6/6 通过。

7.3 真实模型运行效果

三组对照同模型、同任务、同等预算上限，24 次试验全部保留（失败不补跑、不换分母）。

策略	功能验收	完整流程	请求	已知 tokens	格式重试
单 Agent	6/8	6/8	26	123,722	3
固定串行	6/8	6/8	66	451,848	5
动态并行	8/8	7/8	82	575,052	5
合计	20 次候选 10/10	19/24	174	1,150,622	13

本批保留 4 次 HTTP 429、13 次格式重试、1 次本地记录中断；自然代码失败与自然失败后修正均为 0。动态并行组第 7 次功能验收通过但随后模型节点 429，因此“功能成功、流程失败”同时成立并分别记录。其他闭环：四项固定任务 43 请求、313,562 tokens，各 10/10 通过且修正轮次 0；记账项目连续两轮 13/13、20/20，18 请求、136,769 tokens，第二轮主 Agent 自行执行 5 次 Docker 应用工具；Web 自然开发 14/14 生成验收 + 12/12 独立复核（10 请求、131,918 tokens），Web 预设缺陷由真实失败修复至 12/12（4 请求、72,644 tokens）；自主编排内核三次运行共 18 请求。

7.4 性能与并发

可报告的延迟只有运行耗时且包含失败与重试，**不作为加速比或成功率结论**：三组终止记录中位耗时分别 21.08、50.75、49.37 秒。并发约束：API 最多同时执行 2 项自主运行、4 项未结束后台运行、单批最多 3 个并行任务，这些是安全限额而非压测容量。**并发/压力测试与基线对比属决赛补充项，本阶段未完成**；24 次样本只作描述性报告，不宣称多 Agent 普遍更优。

7.5 复现性

9 个历史复现包与同名 `.sha256` 一一对应，2026-11-12 复核 9/9 通过，包含源码、冻结请求、候选、事件、快照与 SHA256 清单。源码与复现包随材料提交、本机可运行；当前未提供公网部署链接。复现命令见附录 A。须如实说明：这些包在本机与既定镜像下可复现流程与校验，换机从零安装复现尚未完成。评审可按附录 A 的 setup→start-sandbox→preflight→workbench 顺序在 Windows 11 上复现演示；无模型 Key 时可浏览已有历史运行与项目证据。

8 人工智能使用说明

8.1 AI 的真实角色

平台以 LLM 为推理核心：需求理解、验收生成、任务拆分与指令、代码修改、失败归因、修复决策、语义审查均由模型完成；宿主负责权限、预算、隔离执行与证据校验。RAG 目前是本地关键词检索（≤3 条片段），工具调用是自研严格 JSON 契约（Function Calling 形态），**未接入 MCP/A2A 标准协议**，也无向量数据库与跨任务长期记忆；这些是赛题鼓励项而非强制项，已列入决赛路线图。团队对代码、测试与本文内容负责，提交前已逐项复核。使用边界：AI 不参与最终裁决——是否通过由冻结验收与宿主校验决定；模型不接触密钥，候选不自动应用，团队对 AI 生成内容承担复核责任。

8.2 各环节作用、贡献与局限

环节	AI/工具	作用	贡献	局限与失败保留
需求与验收	LLM 生成验收	需求转可执行测试并在开发前冻结	验收独立于候选	可能与模型同源，需人工复核
任务规划	主 Agent	动态生成任务、依赖、写入范围	替代固定流水线	协议错误重试；429 打断
编码实现	开发/修正 Agent	生成完整候选与 diff	多模块与 Web 项目	复杂仓库有限；自然失败样本缺失
验收执行	Docker + 可信驱动	禁网容器跑冻结验收	模型自报无法伪造通过	同 UID 非强对抗；启动失败标阻塞
语义审查	审查 Agent	对照需求查遗漏与风险	补测试覆盖不到的需求语义	审查 JSON 可能格式失败
知识检索	关键词 RAG	返回片段与文件路径	上下文可追溯	非向量检索，召回有限
工具调用	自研 JSON 契约	只读检索、文件编辑、容器运行	结果进入事件与反馈	未接 MCP/A2A，工具集较小
运行记录	SQLite 事件/快照	调度、失败、修正全部留证	可回放、审计、恢复	单机库，无多租户

8.3 贡献与失败保留

AI 贡献可量化到真实闭环：三组对照中动态并行功能验收 8/8，单 Agent 与固定串行各 6/8；四项任务 43 请求完成 4×10/10；Web 项目一次自然开发通过两套独立验收。但样本仅 24 次、任务同属一个

TodoStore 代码库，**不能据此计算可靠提升比例。**失败同样保留：4 次 429、13 次格式重试、1 次本地中断、首批 8 次试验 2 成功/6 协议失败、首次预览因 WSL 生命周期退出、依赖准备首次失败等，均可在原始证据中查到，没有被“只展示成功”掩盖。

9 应用成效

平台已真实完成四类任务：标准库 Python 多模块库、CLI 持续迭代、Flask Web 开发与预览、四项固定功能任务批量评测。成功以独立容器验收与审查为准，候选默认不应用，需用户确认。成效衡量的口径是：冻结验收通过率、完整流程完成率、请求与 token 消耗、失败与重试分类，以及证据是否可复现，而不是主观评价。

案例一：Flask 工作项看板。 主 Agent 读取健康页项目后自行拆出后端 API 与前端资产两个无依赖任务并真实并行执行，首个自然候选通过 14 项生成验收与维护者独立冻结的 12 项 HTTP 复核；随后在隔离 iframe 中完成创建、完成切换、筛选、空标题校验与 390px 布局。两个子任务执行区间真实重叠，是并行派发而非串行演示的直接证据。独立预设缺陷实验删除完成状态过滤后，真实 Docker 验收先失败（12 项中 1 项断言失败），模型修复后复验 12/12 通过（4 请求、72,644 tokens）——证明“真实失败→反馈→修正→复验”链路可用，但缺陷是预设的，不计为自然自修复。

案例二：记账 CLI 持续开发。 同一项目从 v1 导入（未验收）到 v2 分类报表 13/13、再到 v3 删除记录 20/20，两轮 18 请求、136,769 tokens；回归验收逐版本继承、旧版本不可变。第二轮主 Agent 自主选择 `edit → tool × 5 → verify → finish`，用五次 Docker 应用工具检查 CLI 并观察到预期负例，工具结果真实进入后续决策，但应用退出 0 不授予验收通过。

案例三：四项对照任务。 完成状态、原子批量编辑、优先级分页、JSON 合并四项任务各有 10 项独立验收，修复后各 10/10（43 请求、313,562 tokens）；三组 24 次对照回答“多 Agent 编排是否值得”：功能 6/8、6/8、8/8，完整流程 6/8、6/8、7/8，同时保留全部失败。结论只在小样本内成立。

场景适配：教学实训中，协作图与事件回放把“如何分工、为何失败”变成可讲解材料，本地部署满足机房网络与数据要求；科研中，小工具快速实现并附带可复现证据包，便于论文附录与交接；企业研发中，模型与工具可替换、源码不出内网、验收可审计，适合内部工具与低风险功能，但当前仍是单机原型，需补齐多用户与部署能力才可进入生产。

10 商业模式

推广模式：以“开源核心 + 课程实训包 + 企业私有化部署”三级推进。开源核心建立信任与技术社区；课程包提供案例、验收库与实验指导书；企业版提供私有部署、模型适配、审计报告与技术支持。当前无公网部署与多用户认证，SaaS 形态暂缓。

市场空间：AI 编程与 Agent 平台快速增长但同质化严重，本项目差异点是“验证可信 + 调度可解释 + 本地可审计”，切入对合规与内网敏感的高校和中小企业研发场景；不作具体市场规模断言，也不宣称已有商业验证。竞争策略上，不与通用编程助手比代码补全速度，而是比“多 Agent 协作是否可验证、失败是否可解释、结果是否可复现”。

生态运作：短期兼容主流模型 API 与 Docker 工具链，中期接入 MCP/A2A 复用外部工具生态，长期建设验收模板与课程案例市场；收入设想为课程授权与实训服务、企业私有化部署与支持、验收模板订阅，均需

决赛后试点验证。阶段目标：初赛后先做 2–3 个高校课程试点与 1 个企业内部试用，验证可用性、支持成本与续费意愿，再决定是否投入多租户与公网版本。

11 团队介绍

- 队伍：奶龙队　学校：湖北工业大学工程技术学院　队伍编号：2117173210695860225
- 项目负责人：王拙诚
- 成员：王拙诚、吴捍卫、黄浩（建议分工：编排与后端、编排调度验证、前端与可视化、测试与材料、答辩演示）
- 指导教师：刘浪

项目代码、测试与文档由团队负责，提交前已逐项复核；团队信息以赛事报名确认为准。

12 风险与后续计划

已知未完成项集中列出，避免在材料中夸大：换机复现、并发压测、MCP/A2A、向量库、多用户鉴权、学生身份证明材料与换机复现；方案书、PPT 已完成，演示视频制作中，团队信息已按报名信息填写。

风险	影响	当前处置	决赛前计划
单机本地工具，无公网部署与多用户认证	无法直接对外服务	标注为本地原型	鉴权、租户隔离与部署文档
Windows + WSL 单点	换机复现困难	记录安装脚本与镜像 ID	Linux 新机从零复现
父子容器同 UID	不抵御恶意代码	仅支持受控示例	评估 gVisor/Firecracker
自然失败自修正样本缺失	不能宣称自修复率	预设缺陷实验单列	采集自然失败与修正样本
知识库为关键词检索	召回有限	标注非向量库	接入 embedding 与向量库
基础镜像 digest 未固定	构建不可重复	记录实际镜像 ID	固定 digest 并重建校验
AI 验收可能与模型同源	验收盲区	维护者独立验收并行	人工评审与交叉模型验收
样本小、任务同源	不能外推	只作描述性报告	扩充任务集与基线对比
学生身份证明/报名材料与演示视频	影响初赛提交完整性	团队信息已填，方案书与 PPT 已产出，视频制作中	11-20 前上传证明材料并完成视频

时间安排：11 月 13–16 日方案书定稿与 10–15 页 PPT；17 日录制 3–5 分钟演示视频；18 日换机复现与材料自检；19 日上传，20 日前最终确认。**成本与限流**：真实实验已遇到 HTTP 429 与未知用量，提交前固定请求间隔与预算上限，演示准备失败可复现的降级脚本（不伪造成功）。**研究价值**：平台把“模型提议、宿主裁决”的编排与验证机制变成可测量对象，可在同一模型与任务上比较不同调度策略、验证强度与预算策略的差异，为多 Agent 可信编排研究提供可复现实验床与失败样本库。若进决赛，重点补调度与验证算法细节、并发/延迟/成功率与基线压力测试、自然失败自我循环样本、教学或企业落地试用证明。

附录 A 复现命令

```
powershell -ExecutionPolicy Bypass -File .\scripts\setup.ps1
powershell -ExecutionPolicy Bypass -File .\scripts\start-sandbox.ps1
.\.venv\Scripts\python.exe scripts\preflight.py
powershell -ExecutionPolicy Bypass -File .\scripts\workbench.ps1
.\.venv\Scripts\python.exe -m pytest -q
cd frontend; npm test; npm run build
.\.venv\Scripts\python.exe scripts\run_live_demo.py --workflow development
.\.venv\Scripts\python.exe scripts\probe_live_repair.py --max-repairs 2 --review
.\.venv\Scripts\python.exe scripts\run_autonomous.py benchmarks\autonomous\sales_report.json --
data-dir .agentforge\my-autonomous-runs --max-tokens 300000 --max-calls 40 --wall-seconds 900
.\.venv\Scripts\python.exe scripts\evaluate_comparison.py --controls <控制证据> --repetitions 2
--max-requests 24 --timeout 600 --output .agentforge\comparisons\<新目录>
.\.venv\Scripts\python.exe scripts\export_reproduction.py --verify output\agentforge-comparison
-reproduction-20261108.zip
```

模型配置只写在本地 `.env`（`AGENTFORGE_LLM_BASE_URL`、`AGENTFORGE_LLM_MODEL`、`AGENTFORGE_LLM_API_KEY`），不进入前端、日志或归档；真实运行可能产生费用。

附录 B 证据索引

证据	说明文档	原始输出
架构与边界	`../docs/architecture.md`	—
依赖与许可证	`../docs/third-party.md`	—
平台测试/构建	—	`../output/delivery-readiness-20261110/pytest-final.txt` 等
三组对照	`../docs/comparison-evaluation.md`	`../output/agentforge-comparison-reproduction-20261108.zip`
四项任务	`../docs/multi-task-evaluation.md`	`../output/agentforge-reproduction-20261108.zip`
自主编排	`../docs/autonomous-orchestration.md`	`../output/agentforge-autonomous-core-20261108.zip`
协作图	`../docs/collaboration-graph-verification.md`	`../output/collaboration-graph-20261108/`
项目持续开发	`../docs/project-workspaces-verification.md`	`../output/agentforge-project-workspaces-20261109.zip`
Web 项目与预览	`../docs/web-projects-validation.md`	`../output/agentforge-web-projects-20261109.zip`
交付页与收尾预算	`../docs/delivery-readiness-20261110.md`	`../output/delivery-readiness-20261110/`
隔离环境	`../docs/sandbox-setup.md`	容器探针记录
全部复现包	—	`../output/*.zip` 与 `.sha256`（9 个，9/9 通过）

所有路径相对本文件 `submission/` 目录；证据文件保持只读，未因撰写方案书而修改。